

Краткое описание решения

Решение строится на агрегации истории событий до уровня `cookie_id`. Для каждого `cookie` использовались только события из заданного 24-часового окна. События сортировались по времени, точные дубликаты удалялись, пропуски обрабатывались отдельно для числовых и категориальных признаков.

Основные группы признаков были выбраны по результатам EDA и на основе предположения, что автоматизированное поведение отличается от человеческого регулярностью и разнообразием действий:

- **Объём и разнообразие активности:** количество событий, уникальных объектов, категорий, запросов и платформ. Эти признаки показывают масштаб и однообразие поведения.
- **Состав событий:** количество и доля событий каждого типа. Они описывают сценарий использования сервиса.
- **Временное поведение:** интервалы между событиями, длительность активности, число активных часов и доля коротких пауз. Боты часто действуют быстрее и регулярнее людей.
- **Курсор:** число событий с координатами, разброс координат и длина перемещений. Эти признаки помогают отличить реальные пользовательские действия от автоматически созданных событий.
- **Повторяемость и синхронность:** повторные обращения к объектам и одновременная активность разных `cookie` вокруг одинаковых объектов. Такие шаблоны могут указывать на массовую автоматизацию.
- **Технические признаки:** платформа, браузер, операционная система, устройство и свойства User-Agent.

Сначала была обучена простая baseline-модель на небольшом наборе очевидных агрегатов. Затем к ней добавлялись новые группы признаков. Каждая группа проверялась на временной валидации: признаки оставались в модели только в том случае, если улучшали качество или давали устойчивый результат на разных периодах. Слишком сложные и нестабильные признаки регулярности и последовательностей событий в финальную версию не вошли.

В качестве моделей использовались CatBoost и LightGBM. Они хорошо подходят для табличных данных, умеют находить нелинейные зависимости и взаимодействия между большим количеством агрегированных признаков. CatBoost удобно и устойчиво работает с категориальными признаками, а LightGBM быстро обучается и хорошо обрабатывает числовые статистики. При этом алгоритмы строят деревья разными способами и могут допускать разные ошибки.

Предсказания CatBoost и LightGBM объединялись с помощью среднего ранга. Такое объединение уменьшает зависимость от масштаба вероятностей каждой модели и делает результат устойчивее. Ансамбль использовался потому, что на временной валидации он работал стабильнее отдельных классификаторов.

Для оценки применялась временная валидация: обучение выполнялось на более ранних датах, а проверка — на следующих. Первые два периода использовались для выбора признаков, последний был оставлен как отдельный holdout. Основной метрикой была **Precision при Recall ≥ 0.7** , дополнительно рассчитывался PR-AUC.

Для воспроизводимости были зафиксированы случайные состояния, включён детерминированный режим LightGBM, а итоговые предсказания усреднялись по пяти seed.